Lesson07---哈希

[本节目标]

- **1. unordered系列关联式容器**
- **2. 底层结构**
- **3. 模拟实现**
- **4.哈希的应用**
- **5.海量数据处理面试题**

1. unordered系列关联式容器

> 在C++98中，STL提供了底层为红黑树结构的一系列关联式容器，在查询时效率可达到$log_2 N$，即最差情况下需要比较红黑树的高度次，当树中的节点非常多时，查询效率也不理想。最好的查询是，进行很少的比较次数就能够将元素找到，因此在C++11中，STL又提供了4个unordered系列的关联式容器，这四个容器与红黑树结构的关联式容器使用方式基本类似，只是其底层结构不同，本文中只对unordered_map和unordered_set进行介绍，unordered_multimap和unordered_multiset学生可查看文档介绍。

1.1 unordered_map

1.1.1 unordered_map的文档介绍

> unordered_map在线文档说明
>
> 1. unordered_map是存储<key, value>键值对的关联式容器，其允许通过keys快速的索引到与其对应的value。
> 2. 在unordered_map中，键值通常用于惟一地标识元素，而映射值是一个对象，其内容与此键关联。键和映射值的类型可能不同。
> 3. 在内部,unordered_map没有对<kye, value>按照任何特定的顺序排序, 为了能在常数范围内找到key所对应的value，unordered_map将相同哈希值的键值对放在相同的桶中。
> 4. unordered_map容器通过key访问单个元素要比map快，但它通常在遍历元素子集的范围迭代方面效率较低。
> 5. unordered_maps实现了直接访问操作符(operator[])，它允许使用key作为参数直接访问value。
> 6. 它的迭代器至少是前向迭代器。

1.1.2 unordered_map的接口说明

> 1. **unordered_map的构造**
>
> | 函数声明 | 功能介绍 |
> | --- | --- |
> | unordered_map | 构造不同格式的unordered_map对象 |
>
> 2. **unordered_map的容量**

函数声明	功能介绍
bool empty() const	检测unordered_map是否为空
size_t size() const	获取unordered_map的有效元素个数

3. unordered_map的迭代器

函数声明	功能介绍
begin	返回unordered_map第一个元素的迭代器
end	返回unordered_map最后一个元素下一个位置的迭代器
cbegin	返回unordered_map第一个元素的const迭代器
cend	返回unordered_map最后一个元素下一个位置的const迭代器

4. unordered_map的元素访问

函数声明	功能介绍
operator[]	返回与key对应的value，没有一个默认值

注意：该函数中实际调用哈希桶的插入操作，用参数key与V()构造一个默认值往底层哈希桶中插入，如果key不在哈希桶中，插入成功，返回V()，插入失败，说明key已经在哈希桶中，将key对应的value返回。

5. unordered_map的查询

函数声明	功能介绍
iterator find(const K& key)	返回key在哈希桶中的位置
size_t count(const K& key)	返回哈希桶中关键码为key的键值对的个数

注意：unordered_map中key是不能重复的，因此count函数的返回值最大为1

6. unordered_map的修改操作

函数声明	功能介绍
insert	向容器中插入键值对
erase	删除容器中的键值对
void clear()	清空容器中有效元素个数
void swap(unordered_map&)	交换两个容器中的元素

7. unordered_map的桶操作

函数声明	功能介绍
size_t bucket_count()const	返回哈希桶中桶的总个数
size_t bucket_size(size_t n)const	返回n号桶中有效元素的总个数
size_t bucket(const K& key)	返回元素key所在的桶号

1.2 unordered_set

> 参见 unordered_set在线文档说明

1.3 在线OJ

> 重复n次的元素

```
class Solution {
public:
 int repeatedNTimes(vector<int>& A) {
     size_t N = A.size()/2;
     // 用unordered_map统计每个元素出现的次数
     unordered_map<int, int> m;
     for(auto e : A)
         m[e]++;

     // 找出出现次数为N的元素
     for(auto& e : m)
     {
         if(e.second == N)
             return e.first;
     }
 }
};
```

> 两个数组的交集I

```
class Solution {
public:
    vector<int> intersection(vector<int>& nums1, vector<int>& nums2) {

     // 用unordered_set对nums1中的元素去重
        unordered_set<int> s1;
        for (auto e : nums1)
            s1.insert(e);

     // 用unordered_set对nums2中的元素去重
        unordered_set<int> s2;
        for (auto e : nums2)
            s2.insert(e);

     // 遍历s1，如果s1中某个元素在s2中出现过，即为交集
        vector<int> vRet;
        for (auto e : s1)
        {
            if (s2.find(e) != s2.end())
                vRet.push_back(e);
        }
```

```
        return vRet;
    }
};
```

[两个数组的交集II]

[存在重复元素]

[两句话中不常见的单词]

2. 底层结构

> unordered系列的关联式容器之所以效率比较高，是因为其底层使用了哈希结构。

2.1 哈希概念

> **顺序结构以及平衡树**中，元素关键码与其存储位置之间没有对应的关系，因此在**查找一个元素时，必须要经过关键码的多次比较。顺序查找时间复杂度为O(N)，平衡树中为树的高度，即O($log_2 N$)**，搜索的效率取决于搜索过程中元素的比较次数。
>
> 理想的搜索方法：可以**不经过任何比较，一次直接从表中得到要搜索的元素。**
> **如果构造一种存储结构，通过某种函数(hashFunc)使元素的存储位置与它的关键码之间能够建立一一映射的关系，那么在查找时通过该函数可以很快找到该元素。**
>
> 当向该结构中：
>
> - **插入元素**
>
> 根据待插入元素的关键码，以此函数计算出该元素的存储位置并按此位置进行存放
> - **搜索元素**
>
> 对元素的关键码进行同样的计算，把求得的函数值当做元素的存储位置，在结构中按此位置取元素比较，若关键码相等，则搜索成功
>
> 该方式即为哈希(散列)方法，**哈希方法中使用的转换函数称为哈希(散列)函数，构造出来的结构称为哈希表(Hash Table)(或者称散列表)**
>
> 例如：数据集合{1，7，6，4，5，9};
>
> 哈希函数设置为：**hash(key) = key % capacity**；capacity为存储元素底层空间总的大小。
>
> 哈希函数：hash(key) = key % capacity　　capacity = 10
>
> | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 |
> |---|---|---|---|---|---|---|---|---|---|
> | | 1 | | | 4 | 5 | 6 | 7 | | 9 |
>
> hash(1) = 1%10 = 1　　hash(7) = 4%10 = 4　　hash(6) = 6%10 = 6
> hash(4) = 4%10 = 4　　hash(5) = 5%10 = 5　　hash(9) = 9%10 = 9
>
> **用该方法进行搜索不必进行多次关键码的比较，因此搜索的速度比较快**
> 问题：按照上述哈希方式，向集合中插入元素44，会出现什么问题？

2.2 哈希冲突

> 对于两个数据元素的关键字k_i和 k_j(i != j)，有k_i != k_j，但有：Hash(k_i) == Hash(k_j)，即：**不同关键字通过相同哈希哈数计算出相同的哈希地址，该种现象称为哈希冲突或哈希碰撞。**

把具有不同关键码而具有相同哈希地址的数据元素称为“同义词”。

发生哈希冲突该如何处理呢?

2.3 哈希函数

引起哈希冲突的一个原因可能是：**哈希函数设计不够合理。**
哈希函数设计原则：

- 哈希函数的定义域必须包括需要存储的全部关键码，而如果散列表允许有m个地址时，其值域必须在0到m-1之间
- 哈希函数计算出来的地址能均匀分布在整个空间中
- 哈希函数应该比较简单

常见哈希函数

1. **直接定址法**--(常用)

   取关键字的某个线性函数为散列地址：Hash（Key）= A*Key + B
   优点：简单、均匀
   缺点：需要事先知道关键字的分布情况
   使用场景：适合查找比较小且连续的情况
   面试题：字符串中第一个只出现一次字符

2. **除留余数法**--(常用)

   设散列表中允许的**地址数为m，取一个不大于m，但最接近或者等于m的质数p作为除数，按照哈希函数：Hash(key) = key% p(p<=m),将关键码转换成哈希地址**

3. **平方取中法**--(了解)

   假设关键字为1234，对它平方就是1522756，抽取中间的3位227作为哈希地址;
   再比如关键字为4321，对它平方就是18671041，抽取中间的3位671(或710)作为哈希地址
   平方取中法比较适合：不知道关键字的分布，而位数又不是很大的情况

4. **折叠法**--(了解)

   折叠法是将关键字从左到右分割成位数相等的几部分(最后一部分位数可以短些)，然后将这几部分叠加求和，并按散列表表长，取后几位作为散列地址。

   折叠法适合事先不需要知道关键字的分布，适合关键字位数比较多的情况

5. **随机数法**--(了解)

   选择一个随机函数，取关键字的随机函数值为它的哈希地址，即H(key) = random(key),其中random为随机数函数。

   通常应用于关键字长度不等时采用此法

6. **数学分析法**--(了解)

   设有n个d位数，每一位可能有r种不同的符号，这r种不同的符号在各位上出现的频率不一定相同，可能在某些位上分布比较均匀，每种符号出现的机会均等，在某些位上分布不均匀只有某几种符号经常出现。可根据散列表的大小，选择其中各种符号分布均匀的若干位作为散列地址。例如：

假设要存储某家公司员工登记表，如果用手机号作为关键字，那么极有可能前7位都是 相同的，那么我们可以选择后面的四位作为散列地址，如果这样的抽取工作还容易出现 冲突，还可以对抽取出来的数字进行反转(如1234改成4321)、右环位移(如1234改成4123)、左环移位、前两数与后两数叠加(如1234改成12+34=46)等方法。

数字分析法通常适合处理关键字位数比较大的情况，如果事先知道关键字的分布且关键字的若干位分布较均匀的情况

注意：哈希函数设计的越精妙，产生哈希冲突的可能性就越低，但是无法避免哈希冲突

2.4 哈希冲突解决

解决哈希冲突两种常见的方法是：**闭散列**和**开散列**

2.4.1 闭散列

闭散列：也叫开放定址法，当发生哈希冲突时，如果哈希表未被装满，说明在哈希表中必然还有空位置，那么可以把key存放到冲突位置中的“下一个” 空位置中去。那如何寻找下一个空位置呢?

1. **线性探测**

   比如2.1中的场景，现在需要插入元素44，先通过哈希函数计算哈希地址，hashAddr为4，因此44理论上应该插在该位置，但是该位置已经放了值为4的元素，即发生哈希冲突。

   线性探测：从发生冲突的位置开始，依次向后探测，直到寻找到下一个空位置为止。

   - **插入**
     - **通过哈希函数获取待插入元素在哈希表中的位置**
     - **如果该位置中没有元素则直接插入新元素，如果该位置中有元素发生哈希冲突，使用线性探测找到下一个空位置，插入新元素**

     哈希函数：hash(key) = key % capacity　　capacity = 10

0	1	2	3	4	5	6	7	8	9
	1			4	5	6	7	44	9

     hash(1) = 1%10 = 1　　hash(7) = 4%10 = 4　　hash(6) = 6%10 = 6

     hash(4) = 4%10 = 4　　hash(5) = 5%10 = 5　　hash(9) = 9%10 = 9

   - **删除**

     采用闭散列处理哈希冲突时，不能随便物理删除哈希表中已有的元素，若直接删除元素会影响其他元素的搜索。比如删除元素4，如果直接删除掉，44查找起来可能会受影响。因此**线性探测采用标记的伪删除法来删除一个元素。**

```
// 哈希表每个空间给个标记
// EMPTY此位置空， EXIST此位置已经有元素， DELETE元素已经删除
enum State{EMPTY, EXIST, DELETE};
```

线性探测的实现

```
// 注意：假如实现的哈希表中元素唯一，即key相同的元素不再进行插入
// 为了实现简单，此哈希表中我们将比较直接与元素绑定在一起
template<class K, class V>
class HashTable
{
    struct Elem
    {
        pair<K, V> _val;
        State _state;
    };

public:
    HashTable(size_t capacity = 3)
        : _ht(capacity), _size(0)
    {
        for(size_t i = 0; i < capacity; ++i)
            _ht[i]._state = EMPTY;
    }

   bool Insert(const pair<K, V>& val)
   {
       // 检测哈希表底层空间是否充足
       // _CheckCapacity();
       size_t hashAddr = HashFunc(key);
       // size_t startAddr = hashAddr;
       while(_ht[hashAddr]._state != EMPTY)
       {
           if(_ht[hashAddr]._state == EXIST && _ht[hashAddr]._val.first
== key)
               return false;

           hashAddr++;
           if(hashAddr == _ht.capacity())
               hashAddr = 0;
           /*
           // 转一圈也没有找到，注意：动态哈希表，该种情况可以不用考虑，哈希表中元
素个数到达一定的数量，哈希冲突概率会增大，需要扩容来降低哈希冲突，因此哈希表中元素是
不会存满的
           if(hashAddr == startAddr)
               return false;
           */
       }

       // 插入元素
       _ht[hashAddr]._state = EXIST;
       _ht[hashAddr]._val = val;
       _size++;
       return true;
   }
   int Find(const K& key)
```

```
    {
        size_t hashAddr = HashFunc(key);
        while(_ht[hashAddr]._state != EMPTY)
        {
            if(_ht[hashAddr]._state == EXIST && _ht[hashAddr]._val.first
== key)
                return hashAddr;

            hashAddr++;
        }
        return hashAddr;
    }
    bool Erase(const K& key)
    {
        int index = Find(key);
        if(-1 != index)
        {
            _ht[index]._state = DELETE;
            _size++;
            return true;
        }
        return false;
    }
    size_t Size()const;
    bool Empty() const;
    void Swap(HashTable<K, V, HF>& ht);
private:
    size_t HashFunc(const K& key)
    {
        return key % _ht.capacity();
    }
private:
    vector<Elem> _ht;
    size_t _size;
};
```

思考：哈希表什么情况下进行扩容？如何扩容？

散列表的载荷因子定义为：α = 填入表中的元素个数 / 散列表的长度

α是散列表装满程度的标志因子。由于表长是定值，α与“填入表中的元素个数”成正比，所以，α越大，表明填入表中的元素越多，产生冲突的可能性就越大；反之，α越小，标明填入表中的元素越少，产生冲突的可能性就越小。实际上，散列表的平均查找长度是载荷因子α的函数，只是不同处理冲突的方法有不同的函数。

对于开放定址法，荷载因子是特别重要因素，应严格限制在0.7-0.8以下。超过0.8，查表时的CPU缓存不命中（cache missing）按照指数曲线上升。因此，一些采用开放定址法的hash库，如Java的系统库限制了荷载因子为0.75，超过此值将resize散列表。

```
void CheckCapacity()
{
    if(_size * 10 / _ht.capacity() >= 7)
    {
        HashTable<K, V, HF> newHt(GetNextPrime(ht.capacity));
        for(size_t i = 0; i < _ht.capacity(); ++i)
        {
            if(_ht[i]._state == EXIST)
                newHt.Insert(_ht[i]._val);
        }

        Swap(newHt);
    }
```

```
}
```

线性探测优点：实现非常简单，

线性探测缺点：**一旦发生哈希冲突，所有的冲突连在一起，容易产生数据“堆积”，即：不同关键码占据了可利用的空位置，使得寻找某关键码的位置需要许多次比较，导致搜索效率降低。**如何缓解呢？

2. **二次探测**

线性探测的缺陷是产生冲突的数据堆积在一块，这与其找下一个空位置有关系，因为找空位置的方式就是挨着往后逐个去找，因此二次探测为了避免该问题，**找下一个空位置的方法为：H_i = (H_0 + i^2)% m, 或者：H_i = (H_0 - i^2)% m。其中：i = 1,2,3…， H_0是通过散列函数Hash(x)对元素的关键码 key 进行计算得到的位置，m是表的大小。**

对于2.1中如果要插入44，产生冲突，使用解决后的情况为：

哈希函数：hash(key) = key % capacity　　capacity = 10

0	1	2	3	4	5	6	7	8	9
	1			4	5	6	7	44	9

hash(1) = 1%10 = 1　hash(7) = 4%10 = 4　hash(6) = 6%10 = 6

hash(4) = 4%10 = 4　hash(5) = 5%10 = 5　hash(9) = 9%10 = 9

研究表明：**当表的长度为质数且表装载因子a不超过0.5时，新的表项一定能够插入，而且任何一个位置都不会被探查两次。因此只要表中有一半的空位置，就不会存在表满的问题。在搜索时可以不考虑表装满的情况，但在插入时必须确保表的装载因子a不超过0.5，**如果超出必须考虑增容。

因此：比散列最大的缺陷就是空间利用率比较低，这也是哈希的缺陷。

2.4.2 开散列

1. **开散列概念**

开散列法又叫链地址法(开链法)，首先对关键码集合用散列函数计算散列地址，具有相同地址的关键码归于同一子集合，每一个子集合称为一个桶，各个桶中的元素通过一个单链表链接起来，各链表的头结点存储在哈希表中。

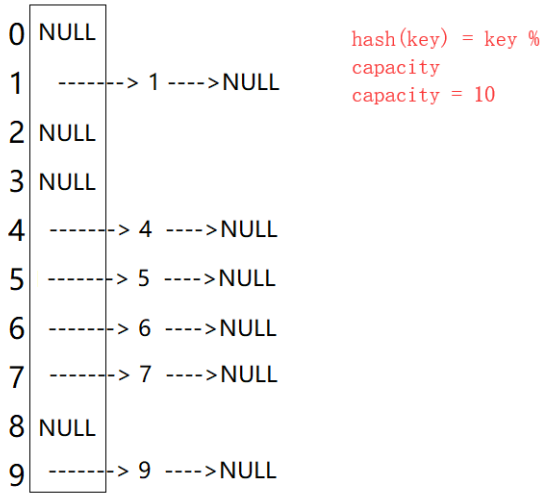

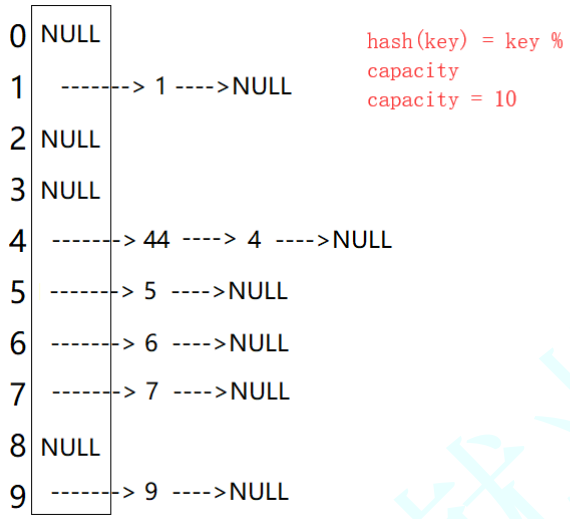

从上图可以看出，**开散列中每个桶中放的都是发生哈希冲突的元素。**

2. **开散列实现**

```
template<class V>
struct HashBucketNode
{
    HashBucketNode(const V& data)
        : _pNext(nullptr), _data(data)
    {}
    HashBucketNode<V>* _pNext;
    V _data;
};

// 本文所实现的哈希桶中key是唯一的
template<class V>
class HashBucket
{
    typedef HashBucketNode<V> Node;
    typedef Node* PNode;
public:
    HashBucket(size_t capacity = 3): _size(0)
    { _ht.resize(GetNextPrime(capacity), nullptr);}

    // 哈希桶中的元素不能重复
    PNode* Insert(const V& data)
    {
        // 确认是否需要扩容。。。
```

```
        // _CheckCapacity();

        // 1. 计算元素所在的桶号
        size_t bucketNo = HashFunc(data);

        // 2. 检测该元素是否在桶中
        PNode pCur = _ht[bucketNo];
        while(pCur)
        {
            if(pCur->_data == data)
                return pCur;

            pCur = pCur->_pNext;
        }

        // 3. 插入新元素
        pCur = new Node(data);
        pCur->_pNext = _ht[bucketNo];
        _ht[bucketNo] = pCur;
        _size++;
        return pCur;
    }

    // 删除哈希桶中为data的元素(data不会重复)，返回删除元素的下一个节点
    PNode* Erase(const V& data)
    {
        size_t bucketNo = HashFunc(data);
        PNode pCur = _ht[bucketNo];
        PNode pPrev = nullptr, pRet = nullptr;

        while(pCur)
        {
            if(pCur->_data == data)
            {
                if(pCur == _ht[bucketNo])
                    _ht[bucketNo] = pCur->_pNext;
                else
                    pPrev->_pNext = pCur->_pNext;

                pRet = pCur->_pNext;
                delete pCur;
                _size--;
                return pRet;
            }
        }

        return nullptr;
    }

    PNode* Find(const V& data);
    size_t Size()const;
    bool Empty()const;
    void Clear();
    bool BucketCount()const;
    void Swap(HashBucket<V, HF>& ht;
    ~HashBucket();
private:
    size_t HashFunc(const V& data)
```

```
    {
        return data%_ht.capacity();
    }
private:
    vector<PNode*> _ht;
    size_t _size;       // 哈希表中有效元素的个数
};
```

3. **开散列增容**

   桶的个数是一定的，随着元素的不断插入，每个桶中元素的个数不断增多，极端情况下，可能会导致一个桶中链表节点非常多，会影响的哈希表的性能，因此在一定条件下需要对哈希表进行增容，那该条件怎么确认呢？开散列最好的情况是：每个哈希桶中刚好挂一个节点，再继续插入元素时，每一次都会发生哈希冲突，因此，在元素个数刚好等于桶的个数时，可以给哈希表增容。

```
void _CheckCapacity()
{
    size_t bucketCount = BucketCount();
    if(_size == bucketCount)
    {
        HashBucket<V, HF> newHt(bucketCount);
        for(size_t bucketIdx = 0; bucketIdx < bucketCount; ++bucketIdx)
        {
            PNode pCur = _ht[bucketIdx];
            while(pCur)
            {
                // 将该节点从原哈希表中拆出来
                _ht[bucketIdx] = pCur->_pNext;

                // 将该节点插入到新哈希表中
                size_t bucketNo = newHt.HashFunc(pCur->_data);
                pCur->_pNext = newHt._ht[bucketNo];
                newHt._ht[bucketNo] = pCur;
                pCur = _ht[bucketIdx];
            }
        }

        newHt._size = _size;
        this->Swap(newHt);
    }
}
```

4. **开散列的思考**

   1. **只能存储key为整形的元素，其他类型怎么解决?**

```
// 哈希函数采用处理余数法，被模的key必须要为整形才可以处理，此处提供将key转化为整形的方法
// 整形数据不需要转化
template<class T>
class DefHashF
{
public:
    size_t operator()(const T& val)
    {
        return val;
```

```
    }
};

// key为字符串类型，需要将其转化为整形
class Str2Int
{
public:
    size_t operator()(const string& s)
    {
        const char* str = s.c_str();
        unsigned int seed = 131; // 31 131 1313 13131 131313
        unsigned int hash = 0;
        while (*str)
        {
            hash = hash * seed + (*str++);
        }

        return (hash & 0x7FFFFFFF);
    }
};

// 为了实现简单，此哈希表中我们将比较直接与元素绑定在一起
template<class V, class HF>
class HashBucket
{
    // ……
private:
    size_t HashFunc(const V& data)
    {
        return HF()(data.first)%_ht.capacity();
    }
};
```

2. **除留余数法，最好模一个素数，如何每次快速取一个类似两倍关系的素数?**

```
size_t GetNextPrime(size_t prime)
        {
            const int PRIMECOUNT = 28;
            static const size_t primeList[PRIMECOUNT] =
            {
                53ul, 97ul, 193ul, 389ul, 769ul,
                1543ul, 3079ul, 6151ul, 12289ul, 24593ul,
                49157ul, 98317ul, 196613ul, 393241ul, 786433ul,
                1572869ul, 3145739ul, 6291469ul, 12582917ul,
25165843ul,
                50331653ul, 100663319ul, 201326611ul, 402653189ul,
805306457ul,
                1610612741ul, 3221225473ul, 4294967291ul
            };

            size_t i = 0;
            for (; i < PRIMECOUNT; ++i)
            {
                if (primeList[i] > prime)
                    return primeList[i];
            }
```

```
            return primeList[i];
        }
```

字符串哈希算法

5. **开散列与闭散列比较**

   应用链地址法处理溢出，需要增设链接指针，似乎增加了存储开销。事实上：
   由于开地址法必须保持大量的空闲空间以确保搜索效率，如二次探查法要求装载因子a <= 0.7，而表项所占空间又比指针大的多，所以使用链地址法反而比开地址法节省存储空间。

3. 模拟实现

3.1 哈希表的改造

1. 模板参数列表的改造

```
// K:关键码类型
// V: 不同容器V的类型不同，如果是unordered_map，V代表一个键值对，如果是unordered_set,V 为 K
// KeyOfValue: 因为V的类型不同，通过value取key的方式就不同，详细见unordered_map/set的实现
// HF: 哈希函数仿函数对象类型，哈希函数使用除留余数法，需要将Key转换为整形数字才能取模
template<class K, class V, class KeyOfValue, class HF = DefHashF<T> >
class HashBucket;
```

2. 增加迭代器操作

```
// 为了实现简单，在哈希桶的迭代器类中需要用到hashBucket本身，
template<class K, class V, class KeyOfValue, class HF>
class HashBucket;

// 注意：因为哈希桶在底层是单链表结构，所以哈希桶的迭代器不需要--操作
template <class K, class V, class KeyOfValue, class HF>
struct HBIterator
{
    typedef HashBucket<K, V, KeyOfValue, HF> HashBucket;
    typedef HashBucketNode<V>* PNode;
    typedef HBIterator<K, V, KeyOfValue, HF> Self;

    HBIterator(PNode pNode = nullptr, HashBucket* pHt = nullptr);
    Self& operator++()
    {
         // 当前迭代器所指节点后还有节点时直接取其下一个节点
        if (_pNode->_pNext)
            _pNode = _pNode->_pNext;
        else
        {
            // 找下一个不空的桶，返回该桶中第一个节点
            size_t bucketNo = _pHt->HashFunc(KeyOfValue()(_pNode->_data))+1;
            for (; bucketNo < _pHt->BucketCount(); ++bucketNo)
            {
                if (_pNode = _pHt->_ht[bucketNo])
                    break;
            }
        }
```

```
        return *this;
    }
    Self operator++(int);
    V& operator*();
    V* operator->();
    bool operator==(const Self& it) const;
    bool operator!=(const Self& it) const;
    PNode _pNode;              // 当前迭代器关联的节点
    HashBucket* _pHt;          // 哈希桶--主要是为了找下一个空桶时候方便
};
```

3. 增加通过key获取value操作

```
template<class K, class V, class KeyOfValue, class HF = DefHashF<T> >
class HashBucket
{
    friend HBIterator<K, V, KeyOfValue, HF>;
    // ......
public:
    typedef HBIterator<K, V, KeyOfValue, HF> Iterator;
    ////////////////////////////////////////////////////
    // ...
    // 迭代器
    Iterator Begin()
    {
        size_t bucketNo = 0;
        for (; bucketNo < _ht.capacity(); ++bucketNo)
        {
            if (_ht[bucketNo])
                break;
        }

        if (bucketNo < _ht.capacity())
            return Iterator(_ht[bucketNo], this);
        else
            return Iterator(nullptr, this);
    }

    Iterator End(){ return Iterator(nullptr, this);}
    Iterator Find(const K& key);
    Iterator Insert(const V& data);
    Iterator Erase(const K& key);

    // 为key的元素在桶中的个数
    size_t Count(const K& key)
    {
        if(Find(key) != End())
            return 1;

        return 0;
    }

    size_t BucketCount()const{ return _ht.capacity();}
    size_t BucketSize(size_t bucketNo)
    {
        size_t count = 0;
```

```
        PNode pCur = _ht[bucketNo];
        while(pCur)
        {
            count++;
            pCur = pCur->_pNext;
        }

        return count;
    }

    // ......
};
```

3.2 unordered_map

```
// unordered_map中存储的是pair<K, V>的键值对，K为key的类型，V为value的类型，HF哈希函数类型
// unordered_map在实现时，只需将hashbucket中的接口重新封装即可
template<class K, class V, class HF = DefHashF<K>>
class unordered_map
{
    typedef pair<K, V> ValueType;
 typedef HashBucket<K, ValueType, KeyOfValue, HF> HT;
 // 通过key获取value的操作
    struct KeyOfValue
    {
        const K& operator()(const ValueType& data)
        { return data.first;}
    };
public:
    typename typedef HT::Iterator iterator;
public:
    unordered_map(): _ht()
    {}
    ////////////////////////////////////////////////////
    iterator begin(){ return _ht.Begin();}
    iterator end(){ return _ht.End();}
    ////////////////////////////////////////////////////////////
    // capacity
    size_t size()const{ return _ht.Size();}
    bool empty()const{return _ht.Empty();}
    ////////////////////////////////////////////////////////////
    // Acess
    V& operator[](const K& key)
    {
        return (*(_ht.InsertUnique(ValueType(key, V())).first)).second;
    }
    const V& operator[](const K& key)const;
    ////////////////////////////////////////////////////////////
    // lookup
    iterator find(const K& key){ return _ht.Find(key);}
    size_t count(const K& key){ return _ht.Count(key);}
    ////////////////////////////////////////////////
    // modify
    pair<iterator, bool> insert(const ValueType& valye)
    { return _ht.Insert(valye);}
```

```
    iterator erase(iterator position)
    { return _ht.Erase(position);}
 ////////////////////////////////////////////////////////
    // bucket
    size_t bucket_count(){ return _ht.BucketCount();}
    size_t bucket_size(const K& key){ return _ht.BucketSize(key);}
private:
    HT _ht;
};
```

4. 哈希的应用

4.1 位图

4.1.1 位图概念

1. 面试题

   给40亿个不重复的无符号整数，没排过序。给一个无符号整数，如何快速判断一个数是否在这40亿个数中。【腾讯】

   1. 遍历，时间复杂度O(N)
   2. 排序(O(NlogN))，利用二分查找: logN
   3. 位图解决

      数据是否在给定的整形数据中，结果是在或者不在，刚好是两种状态，那么可以使用一个二进制比特位来代表数据是否存在的信息，如果二进制比特位为1，代表存在，为0代表不存在。比如：

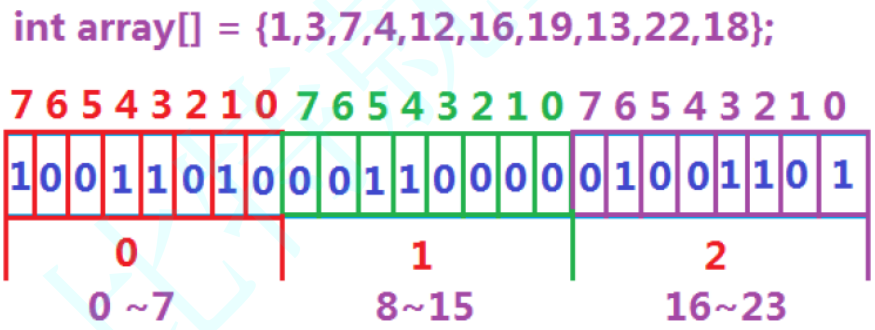

2. 位图概念

   所谓位图，就是用每一位来存放某种状态，适用于海量数据，数据无重复的场景。通常是用来判断某个数据存不存在的。

4.1.2 位图的实现

```
class bitset
{
public:
    bitset(size_t bitCount)
        : _bit((bitCount>>5)+1), _bitCount(bitCount)
    {}
    // 将which比特位置1
    void set(size_t which)
    {
        if(which > _bitCount)
            return;
        size_t index = (which >> 5);
        size_t pos = which % 32;
```

```
        _bit[index] |= (1 << pos);
    }
    // 将which比特位置0
    void reset(size_t which)
    {
        if(which > _bitCount)
            return;
        size_t index = (which >> 5);
        size_t pos = which % 32;
        _bit[index] &= ~(1<<pos);
    }
    // 检测位图中which是否为1
    bool test(size_t which)
    {
        if(which > _bitCount)
            return false;
        size_t index = (which >> 5);
        size_t pos = which % 32;
        return _bit[index] & (1<<pos);
    }
    // 获取位图中比特位的总个数
    size_t size()const{ return _bitCount;}
    // 位图中比特为1的个数
    size_t Count()const
    {
     int bitCnttable[256] = {
 0, 1, 1, 2, 1, 2, 2, 3, 1, 2, 2, 3, 2, 3, 3, 4, 1, 2, 2, 3, 2, 3, 3, 4, 2,
 3, 3, 4, 3, 4, 4, 5, 1, 2, 2, 3, 2, 3, 3, 4, 2, 3, 3, 4, 3, 4, 4, 5, 2, 3,
 3, 4, 3, 4, 4, 5, 3, 4, 4, 5, 4, 5, 5, 6, 1, 2, 2, 3, 2, 3, 3, 4, 2, 3, 3,
 4, 3, 4, 4, 5, 2, 3, 3, 4, 3, 4, 4, 5, 3, 4, 4, 5, 4, 5, 5, 6, 2, 3, 3, 4,
 3, 4, 4, 5, 3, 4, 4, 5, 4, 5, 5, 6, 3, 4, 4, 5, 4, 5, 5, 6, 4, 5, 5, 6, 5,
 6, 6, 7, 1, 2, 2, 3, 2, 3, 3, 4, 2, 3, 3, 4, 3, 4, 4, 5, 2, 3, 3, 4, 3, 4,
 4, 5, 3, 4, 4, 5, 4, 5, 5, 6, 2, 3, 3, 4, 3, 4, 4, 5, 3, 4, 4, 5, 4, 5, 5,
 6, 3, 4, 4, 5, 4, 5, 5, 6, 4, 5, 5, 6, 5, 6, 6, 7, 2, 3, 3, 4, 3, 4, 4, 5,
 3, 4, 4, 5, 4, 5, 5, 6, 3, 4, 4, 5, 4, 5, 5, 6, 4, 5, 5, 6, 5, 6, 6, 7, 3,
 4, 4, 5, 4, 5, 5, 6, 4, 5, 5, 6, 5, 6, 6, 7, 4, 5, 5, 6, 5, 6, 6, 7, 5, 6,
 6, 7, 6, 7, 7, 8};

        size_t size = _bit.size();
        size_t count = 0;
        for(size_t i = 0; i < size; ++i)
        {
            int value = _bit[i];
            int j = 0;
            while(j < sizeof(_bit[0]))
            {
                unsigned char c = value;
                count += bitCntTable[c];
                ++j;
                value >>= 8;
            }
        }
        return count;
    }

private:
    vector<int> _bit;
 size_t _bitCount;
```

```
};
```

4.1.3 位图的应用

1. 快速查找某个数据是否在一个集合中
2. 排序 + 去重
3. 求两个集合的交集、并集等
4. 操作系统中磁盘块标记

4.2 布隆过滤器

4.2.1 布隆过滤器提出

我们在使用新闻客户端看新闻时，它会给我们不停地推荐新的内容，它每次推荐时要去重，去掉那些已经看过的内容。问题来了，新闻客户端推荐系统如何实现推送去重的？ 用服务器记录了用户看过的所有历史记录，当推荐系统推荐新闻时会从每个用户的历史记录里进行筛选，过滤掉那些已经存在的记录。 如何快速查找呢？

1. 用哈希表存储用户记录，缺点：浪费空间
2. 用位图存储用户记录，缺点：位图一般只能处理整形，如果内容编号是字符串，就无法处理了。
3. 将哈希与位图结合，即布隆过滤器

4.2.2布隆过滤器概念

布隆过滤器是由布隆（Burton Howard Bloom）在1970年提出的 一种紧凑型的、比较巧妙的**概率型数据结构**，特点是**高效地插入和查询，可以用来告诉你 “某样东西一定不存在或者可能存在”**，它是用多个哈希函数，将一个数据映射到位图结构中。此种方式**不仅可以提升查询效率，也可以节省大量的内存空间。**

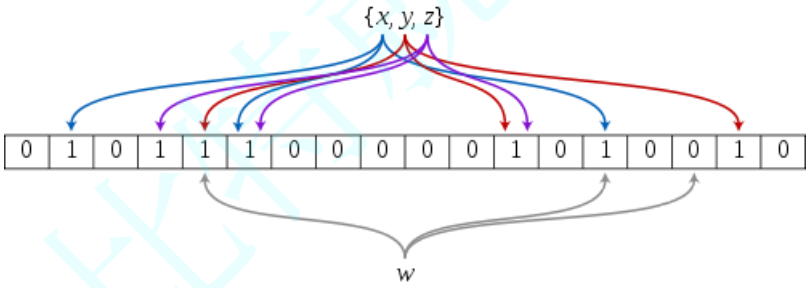

https://zhuanlan.zhihu.com/p/43263751/

4.2.3 布隆过滤器的插入

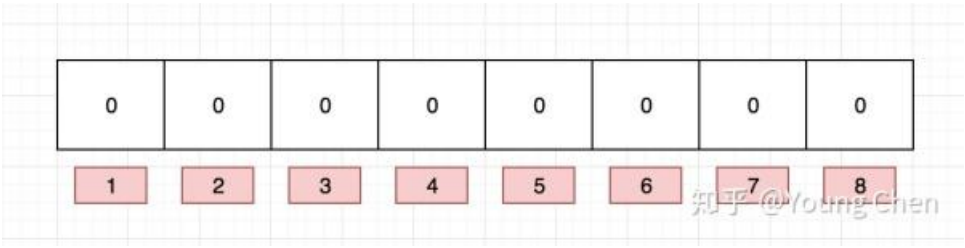

向布隆过滤器中插入："baidu"

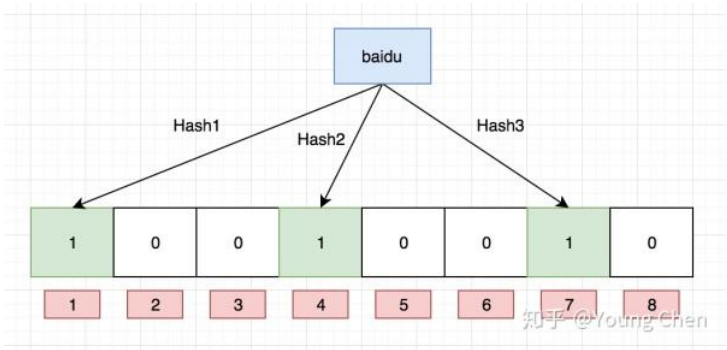

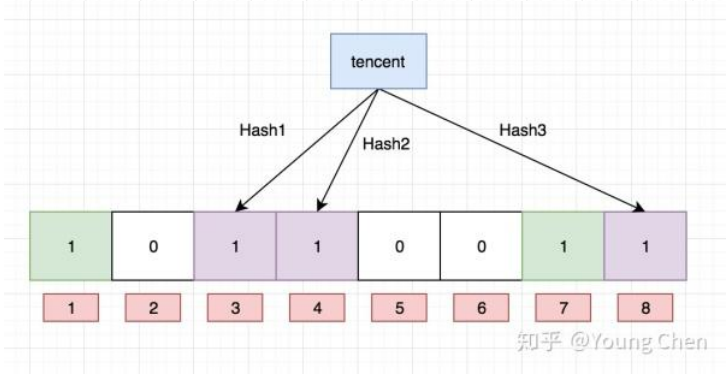


```
struct BKDRHash
{
    size_t operator()(const string& s)
    {
        // BKDR
        size_t value = 0;
        for (auto ch : s)
        {
            value *= 31;
            value += ch;
        }
        return value;
    }
};

struct APHash
{
    size_t operator()(const string& s)
    {
        size_t hash = 0;
        for (long i = 0; i < s.size(); i++)
        {
            if ((i & 1) == 0)
            {
                hash ^= ((hash << 7) ^ s[i] ^ (hash >> 3));
            }
            else
            {
                hash ^= (~((hash << 11) ^ s[i] ^ (hash >> 5)));
            }
        }
        return hash;
    }
};

struct DJBHash
```

```
{
    size_t operator()(const string& s)
    {
        size_t hash = 5381;
        for (auto ch : s)
        {
            hash += (hash << 5) + ch;
        }
        return hash;
    }
};

template<size_t N,
size_t X = 5,
class K = string,
class HashFunc1 = BKDRHash,
class HashFunc2 = APHash,
class HashFunc3 = DJBHash>
class BloomFilter
{
public:
    void Set(const K& key)
    {
        size_t len = X*N;
        size_t index1 = HashFunc1()(key) % len;
        size_t index2 = HashFunc2()(key) % len;
        size_t index3 = HashFunc3()(key) % len;
    /*  cout << index1 << endl;
        cout << index2 << endl;
        cout << index3 << endl<<endl;*/


        _bs.set(index1);
        _bs.set(index2);
        _bs.set(index3);
    }

    bool Test(const K& key)
    {
        size_t len = X*N;
        size_t index1 = HashFunc1()(key) % len;
        if (_bs.test(index1) == false)
            return false;

        size_t index2 = HashFunc2()(key) % len;
        if (_bs.test(index2) == false)
            return false;

        size_t index3 = HashFunc3()(key) % len;

        if (_bs.test(index3) == false)
            return false;

        return true;  // 存在误判的
    }

    // 不支持删除，删除可能会影响其他值。
    void Reset(const K& key);
```

```
private:
    bitset<X*N> _bs;
};
```

4.2.4 布隆过滤器的查找

布隆过滤器的思想是将一个元素用多个哈希函数映射到一个位图中，因此被映射到的位置的比特位一定为1。所以可以按照以下方式进行查找：**分别计算每个哈希值对应的比特位置存储的是否为零，只要有一个为零，代表该元素一定不在哈希表中，否则可能在哈希表中。**

注意：布隆过滤器如果说某个元素不存在时，该元素一定不存在，如果该元素存在时，该元素可能存在，因为有些哈希函数存在一定的误判。

比如：在布隆过滤器中查找"alibaba"时，假设3个哈希函数计算的哈希值为：1、3、7，刚好和其他元素的比特位重叠，此时布隆过滤器告诉该元素存在，但实该元素是不存在的。

4.2.5 布隆过滤器删除

布隆过滤器不能直接支持删除工作，因为在删除一个元素时，可能会影响其他元素。

比如：删除上图中"tencent"元素，如果直接将该元素所对应的二进制比特位置0，“baidu”元素也被删除了，因为这两个元素在多个哈希函数计算出的比特位上刚好有重叠。

一种支持删除的方法：将布隆过滤器中的每个比特位扩展成一个小的计数器，插入元素时给k个计数器(k个哈希函数计算出的哈希地址)加一，删除元素时，给k个计数器减一，通过多占用几倍存储空间的代价来增加删除操作。

缺陷：

1. 无法确认元素是否真正在布隆过滤器中
2. 存在计数回绕

4.2.6 布隆过滤器优点

1. 增加和查询元素的时间复杂度为:O(K), (K为哈希函数的个数，一般比较小)，与数据量大小无关
2. 哈希函数相互之间没有关系，方便硬件并行运算
3. 布隆过滤器不需要存储元素本身，在某些对保密要求比较严格的场合有很大优势
4. 在能够承受一定的误判时，布隆过滤器比其他数据结构有这很大的空间优势
5. 数据量很大时，布隆过滤器可以表示全集，其他数据结构不能
6. 使用同一组散列函数的布隆过滤器可以进行交、并、差运算

4.2.7 布隆过滤器缺陷

1. 有误判率，即存在假阳性(False Position)，即不能准确判断元素是否在集合中(补救方法：再建立一个白名单，存储可能会误判的数据)
2. 不能获取元素本身
3. 一般情况下不能从布隆过滤器中删除元素
4. 如果采用计数方式删除，可能会存在计数回绕问题

5. 海量数据面试题

5.1 哈希切割

给一个超过100G大小的log file, log中存着IP地址, 设计算法找到出现次数最多的IP地址?
与上题条件相同，如何找到top K的IP？如何直接用Linux系统命令实现?

5.2 位图应用

1. 给定100亿个整数，设计算法找到只出现一次的整数?

2. 给两个文件，分别有100亿个整数，我们只有1G内存，如何找到两个文件交集？
3. 位图应用变形：1个文件有100亿个int，1G内存，设计算法找到出现次数不超过2次的所有整数

5.3 布隆过滤器

1. 给两个文件，分别有100亿个query，我们只有1G内存，如何找到两个文件交集？分别给出精确算法和近似算法
2. 如何扩展BloomFilter使得它支持删除元素的操作